

Laboratorio 1: Metodología, EDA y construcción de series

Repositorio del proyecto:

<https://github.com/Isabella1911/DM-Laboratorio-1.-Series-de-Tiempo>

1. Introducción

El laboratorio tuvo como propósito construir una base reproducible para describir y preparar el modelado del ingreso mensual de viajeros a Guatemala mediante técnicas de series de tiempo. El interés analítico estuvo en resumir la evolución temporal del flujo de viajeros, identificar cambios estructurales relevantes y dejar una partición cronológica que permitiera desarrollar la etapa posterior de pronóstico sin mezclar información futura con el conjunto de entrenamiento.

El estudio cubrió el período comprendido entre enero de 2009 y junio de 2026, de acuerdo con la tabla de resumen del conjunto procesado (Tabla 1). A partir de ese período se analizaron siete series mensuales: el total comparable de viajeros, las tres fronteras con mayor volumen acumulado y las tres vías de ingreso disponibles en el archivo refactorizado. Esta selección permitió combinar una visión agregada del fenómeno con aperturas operativas suficientemente representativas para la etapa de diagnóstico inicial.

2. Descripción del conjunto de datos

El insumo utilizado fue el archivo académico `Base_Migracion_2009-2026jun.xlsx`, hoja `Datos`, provisto como base del laboratorio. Después de construir la variable de fecha mensual, la tabla de trabajo quedó compuesta por 161,036 filas y 14 columnas, con cobertura desde 2009-01-01 hasta 2026-06-01, como se resume en la Tabla 1. Las variables principales fueron `Año`, `Mes`, `cod`, `Mes`, `Vía`, `Frontera`, `País`, `Región`, `Región dos`, `Tipo de Viajero` y `Viajero`.

Cuadro 1: Resumen del conjunto de datos procesado.

Indicador	Valor
Numero de filas	161.036
Numero de columnas	14
Inicio del periodo	2009-01-01
Fin del periodo	2026-06-01
Anio inicial	2009
Anio final	2026
Meses distintos	12
Valor minimo de Viajero	0.00
Valor maximo de Viajero	92336.04
Registros negativos en Viajero	0

La variable **Viajero** se interpretó como una cantidad agregada observada para cada combinación de dimensiones, no como un registro individual. Por esa razón, todas las agregaciones temporales y categóricas se realizaron mediante suma. Esta decisión fue central para construir el total mensual y para asegurar que las comparaciones entre fronteras, vías y períodos conservaran la escala original del fenómeno observado.

El conjunto presentó además dos advertencias conceptuales. En primer lugar, la variable **País** perdió comparabilidad estricta después de 2023, porque parte de sus valores pudo responder a agrupaciones de mercado y no a países individuales homogéneos. En segundo lugar, la composición de **Tipo de Viajero** mostró un quiebre operativo entre 2022 y 2023: en 2022 coexistieron **Turista**, **Excursionista**, **Cruceristas** y **Viajero**, mientras que en 2023 ya no apareció **Cruceristas** y se mantuvo **Viajero**. Esa inestabilidad reforzó la decisión metodológica de construir el total comparable únicamente con **Turista** y **Excursionista**, que fueron las categorías presentes de forma consistente a lo largo del horizonte de estudio.

3. Preparación de los datos

3.1. Limpieza y validación

La preparación comenzó con la creación de una variable **fecha** con formato YYYY-MM-01, de modo que cada observación mensual quedara alineada con el inicio del mes. Posteriormente se verificó la consistencia temporal del índice y se reexpresaron las series construidas con frecuencia mensual **MS**. Esta decisión permitió trabajar con una convención uniforme en el análisis exploratorio, la división entrenamiento/prueba y el diagnóstico de estacionariedad.

La revisión de calidad no detectó valores faltantes en las columnas originales del conjunto procesado, tampoco detectó valores negativos en **Viajero** y no encontró duplicados completos. Sí se identificaron 20 posibles duplicados por combinación de dimensiones, por lo que estos casos quedaron marcados para revisión sustantiva en lugar de eliminarse automáticamente. La Tabla 2 resume los principales hallazgos de esta fase.

Cuadro 2: Indicadores de calidad de datos derivados del pipeline refactorizado.

Revision	Resultado
Columnas con faltantes	0
Maximo porcentaje de faltantes	0.0000
Duplicados completos	0
Posibles duplicados dimensionales	20
Outliers globales IQR	26390
Valores negativos en Viajero	0

El análisis de valores atípicos mediante rango intercuartílico identificó 26,390 observaciones extremas a escala global. Sin embargo, estos registros no se trataron como errores por defecto. En un conjunto de movilidad internacional, una parte importante de los extremos pudo corresponder a estacionalidad alta, cierre de fronteras, reaperturas graduales o cambios reales de demanda. Por esa razón, los outliers se documentaron como señales de diagnóstico y no como observaciones a depurar de manera automática.

3.2. Definición del total de viajeros

El total mensual comparable se construyó exclusivamente con las categorías **Turista** y **Excursionista**. Esta decisión no respondió a una preferencia arbitraria, sino a un criterio de consistencia temporal. Las categorías **Viajero** y **Cruceristas** no mantuvieron una definición estable en todo el período y, además, cambiaron de presencia relativa entre 2022 y 2023. En consecuencia, incluirlas en el total habría introducido una discontinuidad conceptual que habría contaminado la comparación longitudinal y el diagnóstico estadístico posterior.

3.3. División de entrenamiento y prueba

La partición del conjunto se hizo de manera cronológica con una proporción aproximada de 70 % para entrenamiento y 30 % para prueba. En la serie total, esta regla produjo 147 meses para entrenamiento y 63 meses para prueba, con fecha de corte en marzo de 2021 e inicio del conjunto de prueba en abril de 2021, como se resume en la Tabla 4. No se utilizó una división aleatoria porque ello habría destruido la dependencia temporal y habría expuesto el entrenamiento a información futura.




Figura 1: Serie mensual total y división cronológica entre entrenamiento y prueba.

La Figura 1 mostró que el corte ocurrió después del choque más severo asociado con la pandemia, lo que permitió que el conjunto de prueba retuviera una etapa de recuperación parcial y, por tanto, un escenario más exigente para la evaluación posterior. El conjunto de entrenamiento se reservó para el análisis exploratorio profundo, la evaluación de transformaciones y el diagnóstico de estacionariedad, mientras que el conjunto de prueba quedó separado para la etapa de comparación de modelos.

4. Análisis exploratorio

4.1. Comportamiento temporal





Figura 2: Comportamiento temporal del volumen mensual filtrado de viajeros.

La Figura 2 mostró una trayectoria con oscilaciones estacionales visibles antes de 2020, seguida por una contracción abrupta durante la pandemia y una recuperación posterior incompleta. A partir de la serie total exportada se observó que el volumen agregado de

2020 cayó aproximadamente 74.4 % respecto de 2019, y que en 2023 todavía se ubicó cerca de 29.4 % por debajo del nivel anual de 2019. El máximo mensual del período ocurrió en diciembre de 2019, mientras que el mínimo se registró en mayo de 2020, lo que confirmó la presencia de una ruptura exógena intensa en la dinámica del sistema.

4.2. Países y regiones




(a) Países con mayor volumen acumulado.

(b) Regiones con mayor volumen acumulado.

Figura 3: Distribución acumulada por país y región.

La Figura 3 indicó un claro predominio regional de Centroamérica y Norteamérica. Entre los países, El Salvador y Guatemala concentraron los mayores volúmenes acumulados, ambos por encima de 13 millones de viajeros, seguidos por Estados Unidos. A nivel regional, América del Centro dominó ampliamente el conjunto con más de 33 millones de viajeros acumulados, muy por encima de América del Norte. Este patrón fue coherente con una estructura de movilidad fuertemente apoyada en proximidad geográfica y conectividad terrestre. No obstante, la advertencia sobre la comparabilidad de País después de 2023 obligó a interpretar estas jerarquías con cautela en la cola final del período.

4.3. Vías y fronteras



(a) Vías de ingreso.

(b) Fronteras con mayor volumen acumulado.

Figura 4: Jerarquía acumulada por vía y frontera.

La Figura 4 mostró que la vía terrestre fue la principal puerta de entrada en términos agregados, seguida por la vía aérea, mientras que la vía marítima mantuvo una escala mucho

menor. En cuanto a fronteras, La Aurora concentró el mayor volumen, seguida por Valle Nuevo y San Cristóbal. Esta concentración justificó que el análisis de series por frontera se enfocara en esas tres unidades, cuyos acumulados se resumen en la Tabla 3.

Cuadro 3: Tres fronteras con mayor volumen acumulado en todo el período filtrado.

Frontera	Viajeros acumulados
01 La Aurora	18.989.985
07 Valle Nuevo	10.143.045
09 San Cristóbal	4.183.632

Los cruces exploratorios entre vía y frontera, así como entre región y vía, mostraron además que el peso de las entradas terrestres estuvo asociado a fronteras específicas de alta intensidad, mientras que la vía aérea se concentró de manera natural en La Aurora. Esta especialización operativa fue relevante porque anticipó diferencias en volatilidad, amplitud estacional y sensibilidad a cierres o restricciones por punto de ingreso.

4.4. Calidad de los datos

La evidencia de calidad respaldó el uso del conjunto sin una depuración agresiva. La ausencia de faltantes en las columnas base y de valores negativos evitó correcciones mecánicas adicionales. En contraste, la presencia de posibles duplicados dimensionales y de un volumen considerable de outliers sugirió una lectura más cuidadosa: estos casos pudieron reflejar desagregaciones administrativas, recategorizaciones o episodios excepcionales de movilidad. Por ello, el criterio metodológico consistió en documentarlos y mantenerlos en el conjunto analítico mientras no existiera evidencia directa de error de captura.

5. Construcción y diagnóstico de las series

Cuadro 4: Resumen de las siete series construidas.

Serie	Inicio	Fin	Frecuencia	Obs.	Fin train	Inicio test
Total mensual	2009-01-01	2026-06-01	MS	210	2021-03-01	2021-04-01
Frontera 01 La Aurora	2009-01-01	2026-06-01	MS	210	2021-03-01	2021-04-01
Frontera 07 Valle Nuevo	2009-01-01	2026-06-01	MS	210	2021-03-01	2021-04-01
Frontera 09 San Cristóbal	2009-01-01	2026-06-01	MS	210	2021-03-01	2021-04-01
Vía Aérea	2009-01-01	2026-06-01	MS	210	2021-03-01	2021-04-01
Vía Terrestre	2009-01-01	2026-06-01	MS	210	2021-03-01	2021-04-01
Vía Marítima	2009-01-01	2026-06-01	MS	210	2021-03-01	2021-04-01

Las siete series se construyeron mediante agregación mensual por suma. El ranking de fronteras se calculó con el acumulado de todo el período ya filtrado por **Turista** y **Excursionista**, y luego se generó una serie mensual para cada una de las tres fronteras líderes. Para las vías de ingreso se construyeron series separadas para Aérea, Terrestre y Marítima. La Tabla 4 mostró que todas las series compartieron el mismo rango temporal

y la misma fecha de corte, lo cual garantizó comparabilidad directa entre diagnósticos. La única diferencia estructural importante apareció en la vía marítima, que conservó meses sin observación y, por tanto, no fue rellenada con ceros para evitar introducir supuestos no justificados sobre ausencia real de viajeros.

5.1. Serie total




Figura 5: Descomposición aditiva de la serie total mensual en entrenamiento.





Figura 6: Diagnóstico de autocorrelación para la serie total en entrenamiento.

La serie total presentó una combinación de tendencia de mediano plazo, patrón estacional y un quiebre pronunciado durante 2020, lo cual quedó reforzado por la descomposición aditiva de la Figura 5. A nivel visual, la amplitud estacional no sugirió un crecimiento de varianza


lo suficientemente fuerte como para exigir una transformación inmediata; por eso el pipeline recomendó mantener la serie sin transformación. En el contraste de Dickey-Fuller aumentado sobre niveles se obtuvo un estadístico de $-2,364$ con $p = 0,1520$, por lo que la evidencia no fue suficiente para tratar la serie de entrenamiento como estacionaria en media. Después de aplicar una primera diferencia, el estadístico pasó a $-2,987$ con $p = 0,0361$, lo que aportó evidencia compatible con estacionariedad tras una diferenciación regular. En consecuencia, para la etapa de modelado posterior se sugirió $d = 1$ y $D = 0$.

La Figura 6 apoyó esta lectura. Las autocorrelaciones en niveles persistieron en varios rezagos, señal característica de una serie no estacionaria en media, mientras que la necesidad de una diferencia estacional no apareció como recomendación principal en el resumen automatizado. Este resultado fue consistente con el fuerte componente de choque exógeno por pandemia: parte de la persistencia temporal pudo provenir de la ruptura estructural y no exclusivamente de una tendencia suave de largo plazo.


5.2. Series por frontera



(a) La Aurora.



(b) Valle Nuevo.



(c) San Cristóbal.

Figura 7: Series mensuales de las tres fronteras con mayor volumen acumulado.

La Figura 7 mostró comportamientos heterogéneos entre fronteras. La Aurora y Valle Nuevo conservaron volúmenes medios más altos y una estacionalidad visible antes del quiebre pandémico, mientras que San Cristóbal operó con menor nivel y mayor sensibilidad relativa a cambios abruptos. En los tres casos, el test ADF sobre niveles no aportó evidencia suficiente de estacionariedad y la primera diferencia sí la aportó, por lo que el pipeline sugirió $d = 1$ y $D = 0$ en las tres fronteras. La principal diferencia apareció en la transformación recomendada: San Cristóbal recibió una sugerencia de transformación tipo Box-Cox

aproximada, mientras que La Aurora y Valle Nuevo conservaron la opción de trabajar sin transformación.

5.3. Series por vía de ingreso




Figura 8: Series mensuales por vía de ingreso.

La Figura 8 permitió distinguir tres escalas operativas. La vía terrestre fue la más voluminosa y también la más expuesta al colapso de 2020; la vía aérea mostró un comportamiento muy cercano al de La Aurora, como cabía esperar por la concentración del tráfico aéreo; y la vía marítima tuvo un nivel mucho menor, con meses faltantes retenidos como ausencia de observación. En términos de media, las tres series requirieron una primera diferencia para obtener evidencia favorable de estacionariedad. En términos de varianza, Aérea y Terrestre mantuvieron la sugerencia de no transformar, mientras que Marítima recibió una recomendación de transformación Box-Cox aproximada debido a una relación más inestable entre nivel y variabilidad.

Cuadro 5: Resumen comparativo del diagnóstico inicial de estacionariedad.

Serie	Transformacion	ADF nivel	p-valor nivel	ADF diff1	p-valor diff1	d	D
Total mensual	sin_transformacion	-2.364	0.1520	-2.987	0.0361	1	0
Frontera 01 La Aurora	sin_transformacion	-2.370	0.1505	-4.075	0.0011	1	0
Frontera 07 Valle Nuevo	sin_transformacion	-1.832	0.3648	-3.536	0.0071	1	0
Frontera 09 San Cristóbal	boxcox_aproximada	-1.393	0.5854	-4.076	0.0011	1	0
Vía Aérea	sin_transformacion	-2.367	0.1512	-4.071	0.0011	1	0
Vía Terrestre	sin_transformacion	-2.117	0.2377	-3.326	0.0137	1	0
Vía Marítima	boxcox_aproximada	0.724	0.9903	-8.731	0.0000	1	0

La Tabla 5 condensó el diagnóstico inicial para las siete series. En todos los casos el valor sugerido para la diferenciación regular fue $d = 1$, mientras que no se recomendó una diferencia estacional adicional ($D = 0$) como primera opción. Este resultado no implicó que la estacionalidad desapareciera, sino que la evidencia del ADF y del flujo automatizado fue suficiente para priorizar una diferencia no estacional en la fase siguiente. En conjunto, la primera parte del trabajo dejó series coherentes, una partición cronológica estable y una base estadística suficiente para iniciar la comparación de modelos en la Parte 2 del laboratorio.

6. Modelos y pronósticos

6.1. Metodología de búsqueda y selección

Para cada una de las 7 series se construyó una rejilla acotada de candidatos ARIMA/SARIMA alrededor de la evidencia de la Parte 1: $d = 1$ para todas las series (valor sugerido por el ADF sobre la primera diferencia), $p, q \in \{0, 1, 2, 3\}$ sin componente estacional, más un pequeño conjunto de variantes estacionales $(1, d, 1) \times (P, D, Q, 12)$ con $P, Q \in \{0, 1\}$ y D tomado del diagnóstico de la Parte 1 (0 en las siete series). Esta rejilla se complementó con `pmdarima.auto_arima` como apoyo, no como sustituto: en varias series el orden sugerido por `auto_arima` coincidió en (p, d, q) con un candidato de la rejilla manual pero reportó un AIC distinto (por ejemplo, para el total mensual `auto_arima` sugirió $(2, 1, 2) \times (1, 0, 1, 12)$ con AIC= 3532,40, mientras que el mismo orden ajustado directamente con `SARIMAX` obtuvo AIC= 3167,86). La diferencia se debe a que `auto_arima` incorpora por defecto un término de tendencia/intercepto que la rejilla manual no incluye; por esa razón se priorizó la rejilla manual, ajustada de forma consistente entre candidatos, y `auto_arima` se usó solo como referencia de órdenes razonables.

De cada rejilla se seleccionaron los tres candidatos con menor AIC como finalistas. A cada finalista se le generó diagnóstico de residuos (serie en el tiempo, histograma, gráfico Q-Q, ACF de residuos y prueba de Ljung-Box en el rezago 12). Además del bloque ARIMA/SARIMA se ajustaron, para todas las series: Prophet (estacionalidad anual, con una covariable binaria que marca el período de pandemia 2020-03 a 2021-12), tres variantes de Holt-Winters (aditivo, aditivo con tendencia amortiguada y, cuando la serie fue estrictamente positiva, multiplicativo), tres variantes de suavizamiento exponencial sin componente estacional (simple, Holt, Holt con tendencia amortiguada) y *seasonal naive* con período 12.

El pronóstico de cada modelo se generó exactamente para el horizonte del conjunto de prueba y, cuando la serie usó una transformación (log o Box-Cox aproximada) en la Parte 1, esa transformación se aplicó antes de ajustar el ARIMA/SARIMA y se revirtió antes de calcular las métricas. El mejor modelo por serie se eligió priorizando el menor RMSE de prueba entre los modelos convergentes cuyos residuos no mostraran autocorrelación significativa (Ljung-Box $p > 0,05$ cuando aplica); el AIC/BIC se usó como criterio secundario dentro de la familia ARIMA/SARIMA, nunca como criterio único, porque en varias series el candidato con mejor AIC en entrenamiento no fue el que mejor generalizó en prueba (se detalla en cada subsección). La única excepción metodológica fue Vía Marítima, sin observaciones de prueba (ver §6.4.1), donde el mejor modelo se eligió por menor AIC en entrenamiento.

6.2. Serie total




Figura 9: Comparación de los cuatro mejores pronósticos para la serie total mensual.

Cuadro 6: Metricas de modelos para la serie total mensual.

serie	modelo	MAE	RMSE	MAPE	AIC	BIC
Total mensual	ARIMA(2, 1, 2)x(1, 0, 1, 12)	237190.29	250633.81	96.53	3167.86	3187.99
Total mensual	ARIMA(1, 1, 1)x(1, 0, 1, 12)	238635.41	251484.82	97.56	3194.75	3209.17
Total mensual	ARIMA(1, 1, 1)x(0, 0, 1, 12)	213333.80	224222.68	87.94	3218.76	3230.29
Total mensual	Prophet	179020.43	193081.63	73.75	–	–
Total mensual	HoltWinters(trend=add,seasonal=add,damped=False)	218366.73	234694.30	85.22	3098.79	3146.64
Total mensual	HoltWinters(trend=add,seasonal=add,damped=True)	171689.57	183893.88	67.51	3097.52	3148.35
Total mensual	HoltWinters(trend=add,seasonal=mul,damped=False)	134374.79	146605.58	51.47	3081.15	3129.00
Total mensual	SuavizamientoExponencial(simple)	165372.54	180598.23	62.91	3177.19	3183.17
Total mensual	SuavizamientoExponencial(holt)	180147.45	196352.92	68.54	3181.16	3193.12
Total mensual	SuavizamientoExponencial(holt_amortiguado)	165379.60	180605.59	62.91	3183.17	3198.12
Total mensual	SeasonalNaive	207321.64	219663.87	84.91	–	–

Para el total mensual, el finalista ARIMA con mejor AIC en entrenamiento, $(2, 1, 2) \times (1, 0, 1, 12)$ (AIC= 3167,86), fue también el de peor desempeño en prueba (RMSE= 250,634), junto con $(1, 1, 1) \times (1, 0, 1, 12)$ (RMSE= 251,485). El mejor modelo global fue HoltWinters(trend=add,seasonal=mul,damped=False) (RMSE= 146605,58, MAE= 134374,79), muy por delante del resto. La Figura 9 y el diagnóstico de residuos del mejor finalista ARIMA (Figura 10) ayudan a explicar por qué: el conjunto de entrenamiento termina en marzo de 2021, en plena recuperación temprana tras el mínimo de la pandemia, y los modelos ARIMA/SARIMA extrapolan esa dinámica de forma casi lineal, mientras que Holt-Winters multiplicativo captura mejor un rebote proporcional al nivel, más parecido a la recuperación real observada 2021-2026.




Figura 10: Diagnóstico de residuos del finalista ARIMA(2,1,2)x(1,0,1,12) para la serie total (mejor AIC, pero peor RMSE de prueba).

6.3. Series por frontera

Cuadro 7: Metricas de modelos para las series por frontera.

serie	modelo	MAE	RMSE	MAPE	AIC	BIC
Frontera 01 La Aurora	ARIMA(0, 1, 0)x(1, 0, 1, 12)	72873.78	77952.82	75.38	2896.87	2905.54
Frontera 01 La Aurora	ARIMA(1, 1, 1)x(1, 0, 1, 12)	70766.55	75820.71	73.15	2901.56	2915.97
Frontera 01 La Aurora	ARIMA(1, 1, 1)x(0, 0, 1, 12)	22967.05	27986.19	22.89	2930.62	2942.15
Frontera 01 La Aurora	Prophet	53092.62	56118.66	60.28	—	—
Frontera 01 La Aurora	Holt Winters(trend=add,seasonal=add,damped=False)	59393.22	64074.54	61.12	2740.20	2788.05
Frontera 01 La Aurora	Holt Winters(trend=add,seasonal=add,damped=True)	42932.58	46855.15	43.78	2740.61	2791.45
Frontera 01 La Aurora	Holt Winters(trend=add,seasonal=mul,damped=False)	25155.78	30236.81	25.04	2734.63	2782.48
Frontera 01 La Aurora	SuavizamientoExponencial(simple)	36821.79	42053.32	36.56	2874.79	2880.77
Frontera 01 La Aurora	SuavizamientoExponencial(holt)	41426.23	46542.04	41.35	2878.78	2890.75
Frontera 01 La Aurora	SuavizamientoExponencial(holt _amortiguado)	36821.79	42053.32	36.56	2880.79	2895.74
Frontera 01 La Aurora	SeasonalNaive	75518.44	79320.76	81.48	—	—
Frontera 07 Valle Nuevo	ARIMA(2, 1, 2)x(1, 0, 1, 12)	47259.00	51920.47	98.02	2853.42	2873.54
Frontera 07 Valle Nuevo	ARIMA(1, 1, 1)x(1, 0, 1, 12)	47478.46	51999.33	99.90	2876.86	2891.27
Frontera 07 Valle Nuevo	ARIMA(1, 1, 1)x(0, 0, 1, 12)	47523.92	52036.78	100.00	2890.20	2901.74
Frontera 07 Valle Nuevo	Prophet	42868.54	47010.38	104.98	—	—
Frontera 07 Valle Nuevo	Holt Winters(trend=add,seasonal=add,damped=False)	39009.41	42001.36	100.04	2787.81	2835.66
Frontera 07 Valle Nuevo	Holt Winters(trend=add,seasonal=add,damped=True)	35211.09	38092.01	85.42	2780.24	2831.07
Frontera 07 Valle Nuevo	Holt Winters(trend=add,seasonal=mul,damped=False)	36691.11	41093.50	73.03	2761.72	2809.57
Frontera 07 Valle Nuevo	SuavizamientoExponencial(simple)	40769.93	45662.79	79.97	2809.12	2815.11
Frontera 07 Valle Nuevo	SuavizamientoExponencial(holt)	43109.45	48125.03	84.30	2813.12	2825.08
Frontera 07 Valle Nuevo	SuavizamientoExponencial(holt _amortiguado)	40768.55	45661.28	79.97	2814.70	2829.65
Frontera 07 Valle Nuevo	SeasonalNaive	44707.23	49660.59	91.39	—	—
Frontera 09 San Cristóbal	ARIMA(0, 1, 2)x(1, 0, 1, 12)	5695.54	7809.73	89.80	1550.79	1565.17
Frontera 09 San Cristóbal	ARIMA(1, 1, 1)x(1, 0, 1, 12)	5065.26	6830.96	89.51	1564.38	1578.79
Frontera 09 San Cristóbal	ARIMA(1, 1, 1)x(0, 0, 1, 12)	22433.07	24911.56	94.83	1579.71	1591.24
Frontera 09 San Cristóbal	Prophet	17823.64	19977.52	100.07	—	—
Frontera 09 San Cristóbal	Holt Winters(trend=add,seasonal=add,damped=False)	22984.98	25463.77	99.22	2597.43	2645.28
Frontera 09 San Cristóbal	Holt Winters(trend=add,seasonal=add,damped=True)	21661.05	24030.56	91.89	2592.03	2642.87
Frontera 09 San Cristóbal	Holt Winters(trend=add,seasonal=mul,damped=False)	17582.55	19904.99	68.40	2584.10	2631.95
Frontera 09 San Cristóbal	SuavizamientoExponencial(simple)	20482.95	23091.34	80.03	2613.03	2619.01
Frontera 09 San Cristóbal	SuavizamientoExponencial(holt)	21503.52	24224.07	83.22	2617.05	2629.01
Frontera 09 San Cristóbal	SuavizamientoExponencial(holt _amortiguado)	20483.60	23092.07	80.03	2619.01	2633.96
Frontera 09 San Cristóbal	SeasonalNaive	21407.95	24052.52	86.23	—	—

En Frontera 01 La Aurora ocurrió un patrón similar al de la serie total: el finalista con mejor AIC, $(0, 1, 0) \times (1, 0, 1, 12)$ (AIC= 2896,87), tuvo RMSE de prueba de 77,953, mientras que $ARIMA(1, 1, 1) \times (0, 0, 1, 12)$ (AIC= 2930,62, el peor de los tres finalistas) obtuvo el mejor RMSE de todos los modelos ajustados (27,986), superando incluso a Holt-Winters multiplicativo (30,237). En Frontera 07 Valle Nuevo, en cambio, ningún ARIMA/SARIMA superó a los métodos de suavizado: el mejor ARIMA (AIC= 2853,42) tuvo RMSE= 51,920, muy por encima del Holt-Winters aditivo con tendencia amortiguada seleccionado (RMSE= 38,092). Frontera 09 San Cristóbal fue la única de las tres donde un ARIMA/SARIMA — $(1, 1, 1) \times (1, 0, 1, 12)$, ajustado sobre la transformación Box-Cox aproximada sugerida en la Parte 1— resultó claramente el mejor modelo (RMSE= 6,831), muy por debajo de Holt-Winters multiplicativo (RMSE= 19,905); es también la frontera con menor volumen y mayor volatilidad relativa, por lo que la transformación de varianza parece haber ayudado más que en las otras dos.




Figura 11: Diagnóstico de residuos del modelo seleccionado para Frontera 01 La Aurora, ARIMA(1,1,1)x(0,0,1,12).

6.4. Series por vía de ingreso

Cuadro 8: Metricas de modelos para las series por via de ingreso.

serie	modelo	MAE	RMSE	MAPE	AIC	BIC
Vía Aérea	ARIMA(0, 1, 0)x(1, 0, 1, 12)	73006.22	78140.71	75.45	2897.17	2905.84
Vía Aérea	ARIMA(1, 1, 1)x(1, 0, 1, 12)	70831.33	75940.72	73.16	2901.92	2916.33
Vía Aérea	ARIMA(1, 1, 1)x(0, 0, 1, 12)	22914.63	27998.65	22.79	2930.95	2942.48
Vía Aérea	Prophet	52606.20	55660.59	59.75	–	–
Vía Aérea	HoltWinters(trend=add,seasonal=add,damped=False)	59521.52	64256.05	61.19	2740.53	2788.38
Vía Aérea	HoltWinters(trend=add,seasonal=add,damped=True)	43002.67	46980.16	43.79	2740.96	2791.80
Vía Aérea	HoltWinters(trend=add,seasonal=mul,damped=False)	25453.98	30455.53	25.38	2734.83	2782.68
Vía Aérea	SuavizamientoExponencial(simple)	36970.60	42141.22	36.75	2875.29	2881.27
Vía Aérea	SuavizamientoExponencial(holt)	41663.82	46728.04	41.61	2879.28	2891.24
Vía Aérea	SuavizamientoExponencial(holt _amortiguado)	36970.60	42141.22	36.75	2881.28	2896.24
Vía Aérea	SeasonalNaive	75512.73	79339.80	81.48	–	–
Vía Terrestre	ARIMA(2, 1, 3)x(1, 0, 1, 12)	147367.15	158502.36	99.66	3067.59	3090.53
Vía Terrestre	ARIMA(1, 1, 1)x(1, 0, 1, 12)	147494.21	158548.37	99.93	3114.25	3128.66
Vía Terrestre	ARIMA(1, 1, 1)x(0, 0, 1, 12)	147532.18	158564.18	100.00	3135.05	3146.59
Vía Terrestre	Prophet	123423.17	134941.03	89.09	–	–
Vía Terrestre	HoltWinters(trend=add,seasonal=add,damped=False)	145591.06	157840.43	94.73	3030.88	3078.72
Vía Terrestre	HoltWinters(trend=add,seasonal=add,damped=True)	128386.45	139123.21	82.56	3027.48	3078.31
Vía Terrestre	HoltWinters(trend=add,seasonal=mul,damped=False)	107808.72	118717.14	65.63	3001.02	3048.86
Vía Terrestre	SuavizamientoExponencial(simple)	121715.66	134136.26	74.64	3078.96	3084.94
Vía Terrestre	SuavizamientoExponencial(holt)	130054.59	143087.97	79.71	3082.94	3094.90
Vía Terrestre	SuavizamientoExponencial(holt _amortiguado)	121717.95	134138.62	74.64	3084.88	3099.83
Vía Terrestre	SeasonalNaive	132209.04	144274.98	84.83	–	–
Vía Marítima	ARIMA(0, 1, 1)x(1, 0, 1, 12)	–	–	–	522.91	532.49
Vía Marítima	ARIMA(1, 1, 1)x(1, 0, 1, 12)	–	–	–	524.91	536.89
Vía Marítima	ARIMA(1, 1, 1)x(1, 0, 0, 12)	–	–	–	549.93	559.55
Vía Marítima	Prophet	–	–	–	–	–
Vía Marítima	HoltWinters(trend=add,seasonal=add,damped=False)	–	–	–	941.68	982.71
Vía Marítima	HoltWinters(trend=add,seasonal=add,damped=True)	–	–	–	940.07	983.67
Vía Marítima	HoltWinters(trend=add,seasonal=mul,damped=False)	–	–	–	937.51	978.54
Vía Marítima	SuavizamientoExponencial(simple)	–	–	–	1032.02	1037.15
Vía Marítima	SuavizamientoExponencial(holt)	–	–	–	1035.29	1045.55
Vía Marítima	SuavizamientoExponencial(holt _amortiguado)	–	–	–	1038.16	1050.99
Vía Marítima	SeasonalNaive	–	–	–	–	–

Vía Aérea reprodujo casi exactamente el comportamiento de Frontera 01 La Aurora (mismo modelo ganador, $ARIMA(1, 1, 1) \times (0, 0, 1, 12)$, $RMSE = 27,999$), consistente con que la Aurora concentra la enorme mayoría del tráfico aéreo. Vía Terrestre, la de mayor volumen absoluto, fue mejor pronosticada por Holt-Winters multiplicativo ($RMSE = 118,717$) que por cualquier ARIMA/SARIMA (mejor ARIMA con $RMSE = 158,502$), repitiendo el patrón de la serie total.

6.4.1. Caso especial: Vía Marítima

Al construir y depurar las series de la Parte 1 se detectó que Vía Marítima solo tiene observaciones reales entre enero de 2009 y diciembre de 2016; a partir de 2017 no existe ningún registro en el conjunto de datos para esa vía, por lo que el 100 % del conjunto de prueba (abril 2021 a junio 2026) carece de valor real contra el cual evaluar un pronóstico. Los modelos ARIMA/SARIMA, Holt-Winters, suavizamiento exponencial y *seasonal naive* se ajustaron igualmente sobre el tramo válido y contiguo 2009-2016 (96 observaciones) y generan un pronóstico de 63 meses hacia adelante con fines exploratorios, pero MAE, RMSE y MAPE no son evaluables y se reportan como N/D . Ante la ausencia de una métrica de prueba, el mejor modelo se seleccionó por menor AIC en entrenamiento: $ARIMA(0, 1, 1) \times (1, 0, 1, 12)$

(AIC= 522,91). Esta discontinuidad se trata como un hallazgo en sí mismo en la Sección 7.3, no como un error de procesamiento.

6.5. Resumen comparativo

Cuadro 9: Mejor modelo seleccionado para cada serie (justificación en el texto).

serie	modelo_seleccionado	MAE	RMSE	AIC	BIC
Total mensual	HW(mul,amort=False)	134374.79	146605.58	3081.15	3129.00
Frontera 01 La Aurora	ARIMA(1, 1, 1)x(0, 0, 1, 12)	22967.05	27986.19	2930.62	2942.15
Frontera 07 Valle Nuevo	HW(add,amort=True)	35211.09	38092.01	2780.24	2831.07
Frontera 09 San Cristóbal	ARIMA(1, 1, 1)x(1, 0, 1, 12)	5065.26	6830.96	1564.38	1578.79
Vía Aérea	ARIMA(1, 1, 1)x(0, 0, 1, 12)	22914.63	27998.65	2930.95	2942.48
Vía Terrestre	HW(mul,amort=False)	107808.72	118717.14	3001.02	3048.86
Vía Marítima	ARIMA(0, 1, 1)x(1, 0, 1, 12)	–	–	522.91	532.49




Figura 12: RMSE de prueba del mejor modelo por serie (Vía Marítima omitida por falta de datos de prueba).

La Tabla 9 y la Figura 12 resumen el patrón general: Holt-Winters (variantes aditiva o multiplicativa) ganó en las series de mayor volumen y con quiebre estructural más marcado por la pandemia (Total mensual, Vía Terrestre, Frontera 07 Valle Nuevo), mientras que ARIMA/SARIMA ganó en las series donde La Aurora domina el flujo (Frontera 01 La Aurora, Vía Aérea) y en la serie de menor escala con transformación de varianza (Frontera 09 San Cristóbal). En ningún caso el modelo con mejor AIC/BIC de entrenamiento fue automáticamente el de mejor RMSE de prueba, lo que confirma la necesidad de comparar ambos criterios en lugar de escoger solo por ajuste dentro de muestra.



Figura 13: Pronóstico del mejor modelo contra el valor real, para cada una de las siete series, en el conjunto de prueba.




Figura 14: Valores reales contra predichos del mejor modelo de cada serie (conjunto de prueba).

7. Análisis comparativo

Esta sección responde, con la evidencia estadística de la Tabla 10 (fronteras) y la Tabla 11 (vías), las preguntas comparativas del laboratorio. La fuerza de estacionalidad se calculó como $F_s = \max(0, 1 - \text{Var}(\text{residuo})/\text{Var}(\text{estacional} + \text{residuo}))$ sobre la descomposición aditiva de cada serie completa; la tendencia se resume con la pendiente de la componente de tendencia descompuesta; la volatilidad, con el coeficiente de variación; y el impacto de la pandemia, con la caída porcentual del mínimo de 2020 frente al promedio de 2019 y los meses necesarios para volver a ese promedio. Los porcentajes de *crecimiento post-pandemia* calculados sobre el mínimo de 2020 no se usan como evidencia principal de tendencia porque, al partir de una base casi nula, producen variaciones porcentuales artificialmente enormes (ver `outputs/parte3/comparacion_modelos_global.csv`); se prioriza en su lugar la pendiente de la tendencia y el crecimiento pre-pandemia (2019 contra el primer año completo disponible).

7.1. Fronteras

Cuadro 10: Comparacion estadística entre las tres fronteras principales (MAE/RMSE del mejor modelo en la Tabla 9).

serie	fuerza_estacionalidad	pendiente_tendencia	coeficiente_variacion	caida_porcentual	meses_recuperacion	mejor_modelo
Frontera 01 La Aurora	0.57	50.27	0.31	-99.61	27	ARIMA(1, 1, 1)x(0, 0, 1, 12)
Frontera 07 Valle Nuevo	0.36	58.54	0.49	-99.90	24	HW(add,amort=True)
Frontera 09 San Cristóbal	0.31	65.03	0.57	-99.96	18	ARIMA(1, 1, 1)x(1, 0, 1, 12)




Figura 15: Series mensuales completas de las tres fronteras principales.




Figura 16: Distribución mensual (boxplot por mes) de cada frontera principal.

- **Mayor estacionalidad:** Frontera 01 La Aurora ($F_s = 0,57$), la más alta de las tres, coherente con un aeropuerto cuya demanda se concentra en temporadas vacacionales específicas.
- **Mayor tendencia de crecimiento:** Frontera 09 San Cristóbal, con la pendiente de tendencia más pronunciada (65.0 viajeros/mes) y el mayor crecimiento acumulado 2009-2019 (237.9 % frente a 59.0 % en La Aurora y 152.2 % en Valle Nuevo), es decir, la frontera que más creció de forma sostenida antes de la pandemia.

- **Mayor volatilidad:** Frontera 09 San Cristóbal, con el coeficiente de variación más alto (0.57) de las tres, reflejo de su menor volumen absoluto y mayor sensibilidad relativa a choques.
- **Más afectada por la pandemia:** en caída porcentual, Frontera 09 San Cristóbal fue la más golpeada (-99.96 % frente al promedio de 2019), pero también la que más rápido recuperó su nivel previo (18 meses), precisamente por partir de un volumen pequeño. Frontera 01 La Aurora, con una caída relativa apenas menor (-99.61 %), tardó más en términos absolutos (27 meses) por tener que recuperar un volumen mensual varias veces mayor.

7.2. Vías de ingreso

Cuadro 11: Comparacion estadistica entre las tres vias de ingreso (MAE/RMSE del mejor modelo en la Tabla 9).

serie	fuerza_estacionalidad	pendiente_tendencia	coeficiente_variacion	caida_porcentual	meses_recuperacion	mejor_modelo
Vía Aérea	0.57	48.87	0.31	-99.60	27	ARIMA(1, 1, 1)x(0, 0, 1, 12)
Vía Terrestre	0.43	351.80	0.46	-97.63	24	HW(mul,amort=False)
Vía Marítima	0.77	-1.21	0.21	—	sin_datos_suficientes	ARIMA(0, 1, 1)x(1, 0, 1, 12)




Figura 17: Series mensuales completas de las tres vías de ingreso.




Figura 18: Distribución mensual (boxplot por mes) de cada vía de ingreso.

Las fronteras y las vías no se comparan en una sola clasificación conjunta: una frontera es un punto físico de ingreso y una vía agrupa varias fronteras (por ejemplo, Vía Aérea incluye a La Aurora y otros aeropuertos menores), por lo que sus escalas y su composición no son directamente equivalentes.

- **Mayor estacionalidad:** tomando solo las dos vías con historia completa y comparable, Vía Aérea ($F_s = 0,57$) supera a Vía Terrestre ($F_s = 0,43$). Vía Marítima muestra un valor numérico más alto (0.77), pero se calcula únicamente sobre 2009-2016 (su único tramo con datos), por lo que no es comparable en igualdad de condiciones y no se usa para esta conclusión.
- **Mayor tendencia de crecimiento:** Vía Terrestre, con una pendiente de tendencia muchísimo mayor (352 viajeros/mes) y un crecimiento pre-pandemia de 184.1 % frente a 58.6 % en Vía Aérea.
- **Mayor volatilidad:** Vía Terrestre (coeficiente de variación 0.46) frente a Vía Aérea (0.31); nuevamente se excluye Vía Marítima de la comparación por la misma razón de ventana de datos incompleta.
- **Más afectada por la pandemia:** en el sentido cíclico (caída y recuperación), Vía Aérea sufrió la mayor caída porcentual (-99.60 % frente a -97.63 % en Vía Terrestre), coherente con el cierre casi total de fronteras aéreas internacionales en 2020. En un sentido más estructural, Vía Marítima es la más afectada de las tres: no se trata de una caída cíclica sino de una interrupción que nunca se revirtió, pues no vuelve a tener registros después de 2016.

7.3. Hallazgos para INGUAT




Figura 19: Índice de viajeros (2019 = 100) antes, durante y después de la pandemia, por frontera y vía.

A partir de las tablas y figuras anteriores, los hallazgos con mayor potencial de uso para la planificación del INGUAT son:

1. **Recuperación desigual entre fronteras.** Frontera 01 La Aurora tardó 27 meses en volver a su nivel de 2019, la más lenta de las tres, pese a no ser la que sufrió la mayor caída porcentual. La capacidad de recuperación no depende solo de la severidad de la caída relativa, sino del volumen absoluto que hay que recuperar; esto sugiere priorizar apoyo operativo y promoción diferenciada en La Aurora en escenarios de choque futuro.
2. **Concentración estacional en La Aurora.** Con la mayor fuerza de estacionalidad entre fronteras (0.57), La Aurora concentra su demanda en meses recurrentes específicos, lo que es útil para planificar capacidad migratoria y de infraestructura en temporada alta.
3. **Vía Terrestre concentra la mayor incertidumbre.** Con el coeficiente de variación más alto entre vías (0.46) y el mayor volumen absoluto del país, es la vía más difícil de pronosticar con precisión y la más sensible a choques externos; conviene monitorearla con mayor frecuencia y usar intervalos de pronóstico amplios.
4. **El riesgo pandémico no se distribuyó igual entre vías.** Vía Aérea sufrió la mayor caída porcentual (-99.6 %); depender de una sola vía concentra el riesgo ante un choque futuro similar, por lo que diversificar la promoción entre vías reduce la exposición del sector turístico a un cierre de fronteras aéreas.
5. **El desempeño de los modelos no es uniforme entre series.** La serie total mensual tuvo el mayor RMSE de prueba entre todas las series modeladas, señal de que los cambios estructurales recientes (recuperación pospandemia) son más difíciles de capturar a nivel agregado que a nivel de frontera o vía individual; el seguimiento operativo del INGUAT se beneficia de monitorear las series desagregadas, no solo el total.

6. **Vía Marítima dejó de reportarse desde 2017.** Independientemente de cualquier modelo de pronóstico, el hallazgo más accionable de esta vía es que el propio dato desapareció: si la vía marítima sigue existiendo operativamente, el INGUAT debería revisar por qué dejó de registrarse en esta fuente, ya que ningún modelo estadístico puede compensar la ausencia total de información reciente.

Estos hallazgos muestran asociación temporal y estadística entre eventos (pandemia, estacionalidad, tipo de vía) y el comportamiento de los flujos de viajeros; no se interpretan como relaciones causales, ya que el diseño del estudio es observacional y no permite descartar otros factores externos (política migratoria, oferta de vuelos, condiciones económicas regionales) que pudieron actuar simultáneamente.

8. Laboratorio 2: Deep Learning

8.1. Modelos LSTM (Ejercicio 1)

Para el Ejercicio 1 se seleccionaron dos series del Laboratorio 1 – el total mensual (obligatoria) y Frontera 01 La Aurora (la de mayor volumen acumulado) – y se reutilizaron exactamente los mismos conjuntos de entrenamiento y prueba (Tabla 12), sin ninguna división aleatoria. TensorFlow no publica ruedas para la versión de Python usada, por lo que se implementó con **Keras 3 sobre backend Torch**, conservando la misma API (**Sequential**, **LSTM**, **EarlyStopping**) del enunciado.

Cuadro 12: Conjuntos de entrenamiento y prueba reutilizados del Laboratorio 1.

Serie	Observaciones de entrenamiento	Observaciones de prueba	Inicio de entrenamiento	Fin de entrenamiento	Inicio de prueba	Fin de prueba
Total mensual	147	63	2009-01-01	2021-03-01	2021-04-01	2026-06-01
Frontera 01 La Aurora	147	63	2009-01-01	2021-03-01	2021-04-01	2026-06-01

Para cada serie se evaluaron cuatro configuraciones LSTM (Tablas 13 y 14), variando el tamaño de la ventana de rezagos (**look_back**), el número de unidades y de capas LSTM, el *dropout*, la tasa de aprendizaje y el tamaño de lote. La selección de hiperparámetros se hizo **únicamente con un conjunto de validación temporal** (el 20 % final del entrenamiento), nunca con el conjunto de prueba, y se usó **EarlyStopping** sobre la pérdida de validación para evitar sobreajuste.

Cuadro 13: Tuneo de configuraciones LSTM – Total mensual (metricas de validacion).

modelo	look_back	unidades_1	unidades_2	dropout	learning_rate	batch_size	mejor_epoca	val_MAE	val_RMSE	val_R2
LSTM_1	6	32	–	0.10	0.00	16	59	75504.63	110768.93	0.51
LSTM_2	12	64	–	0.20	0.00	16	5	97317.94	128028.40	0.33
LSTM_3	12	64	32.00	0.20	0.00	32	3	118098.43	132251.04	0.29
LSTM_4	24	64	32.00	0.30	0.00	32	2	128620.23	141499.14	0.20

Cuadro 14: Tuneo de configuraciones LSTM – Frontera 01 La Aurora (metricas de validacion).

modelo	look_back	unidades_1	unidades_2	dropout	learning_rate	batch_size	mejor_epoca	val_MAE	val_RMSE	val_R2
LSTM_1	6	32	–	0.10	0.00	16	5	31458.35	43493.34	0.38
LSTM_2	12	64	–	0.20	0.00	16	5	34162.54	46284.52	0.26
LSTM_3	12	64	32.00	0.20	0.00	32	3	41744.55	47011.25	0.24
LSTM_4	24	64	32.00	0.30	0.00	32	2	44518.46	50108.25	0.16




Figura 20: Pérdida de validación por época para las cuatro configuraciones LSTM: Total mensual (izquierda) y Frontera 01 La Aurora (derecha).

En ambas series la configuración con menor RMSE de validación fue **LSTM_1** (`look_back=6`, una sola capa LSTM de 32 unidades, `dropout=0.1`, `learning_rate=0.001`), la arquitectura más simple de las cuatro evaluadas; las configuraciones con dos capas o ventanas más largas (LSTM_3, LSTM_4) no mejoraron la validación, señal de que una ventana corta basta para capturar la dependencia relevante en estas series mensuales y que arquitecturas más profundas solo agregan varianza con esta cantidad de datos.

8.1.1. Predicción con el mejor modelo




Figura 21: Predicción del mejor modelo LSTM contra el valor real en el conjunto de prueba: Total mensual (izquierda) y Frontera 01 La Aurora (derecha).

Cuadro 15: Mejor modelo LSTM por serie, evaluado en el conjunto de prueba.

Serie	Mejor modelo	Look back	MAE prueba	RMSE prueba	MAPE prueba	R2 prueba
Total mensual	LSTM_1	6	40554.44	50794.23	18.05	0.54
Frontera 01 La Aurora	LSTM_1	6	15908.09	19295.30	18.82	0.29

8.1.2. ¿Cuál predijo mejor y es mejor que el Laboratorio 1?

Cuadro 16: LSTM contra el mejor modelo del Laboratorio 1, mismo conjunto de prueba.

Serie	Modelo	MAE	RMSE	MAPE
Total mensual	HoltWinters(trend=add,seasonal=mul,damped=False)	134374.79	146605.58	51.47
Total mensual	LSTM (LSTM_1)	40554.44	50794.23	18.05
Frontera 01 La Aurora	ARIMA(1, 1, 1)x(0, 0, 1, 12)	22967.05	27986.19	22.89
Frontera 01 La Aurora	LSTM (LSTM_1)	15908.09	19295.30	18.82

La Tabla 16 compara, sobre el mismo conjunto de prueba, el mejor LSTM de cada serie contra el mejor modelo clásico del Laboratorio 1. En **Total mensual**, LSTM obtuvo RMSE=50 794 frente a 146 606 de Holt-Winters multiplicativo (una reducción de 65.4 %); en **Frontera 01 La Aurora**, LSTM obtuvo RMSE=19 295 frente a 27 986 del mejor ARIMA estacional (una reducción de 31.1 %). En ambos casos LSTM generalizó mejor sobre el mismo horizonte de prueba, que cubre precisamente la recuperación pospandemia – el tramo más difícil de pronosticar para los modelos del Laboratorio 1 (Sección 6.4.1 y siguientes). Entre las dos series, **Total mensual** tuvo el MAPE de prueba más bajo (18.05 % frente a 18.82 % en La Aurora), aunque la diferencia es pequeña y ambas series quedan en un rango de error relativo similar. El criterio usado para decidir “mejor modelo” en todos los casos fue el mismo del Laboratorio 1: menor RMSE de prueba, con MAE y MAPE como evidencia secundaria, y sin usar nunca el conjunto de prueba durante el tuneo de hiperparámetros.

8.2. Similitud de series con catch22 (Ejercicio 2)

8.2.1. Idea detrás de catch22

catch22 (Lubba et al., 2019, sobre la base de Fulcher, Little y Jones, 2013) parte de que existen miles de formas de caracterizar estadísticamente una serie de tiempo (autocorrelación, entropía, no linealidad, distribución de valores, estructura estacional, etc.), pero muchas de ellas están correlacionadas entre sí y aportan información redundante. Su equipo evaluó miles de características de la librería `hctsa` sobre miles de series reales y sintéticas, y seleccionó las **22 características** que, en conjunto, maximizan el poder de discriminación entre series con la menor redundancia posible entre ellas, además de ser rápidas de calcular. Es importante porque permite resumir una serie completa en un vector corto de 22 números comparable entre series de distinta longitud o escala, sin necesidad de alinearlas en el tiempo.

8.2.2. Extracción, matriz y estandarización

Se extrajeron las 22 características de catch22 para las siete series del Laboratorio 1, usando en cada caso únicamente sus observaciones válidas: las seis series con historia completa (2009-2026) y **Vía Marítima**, que solo tiene observaciones reales entre 2009 y 2016 (dejó de reportarse desde 2017, como se documentó en la Sección 6.4.1) y cuyas características se calcularon exclusivamente sobre ese tramo válido. La matriz resultante (7 series × 22 características) se estandarizó (media 0, desviación 1 por columna) antes de cualquier análisis comparativo.

8.2.3. PCA, clustering, heatmap, correlación y distancias




Figura 22: PCA sobre las características catch22 estandarizadas de las siete series.

Las dos primeras componentes principales explican el 80.6 % de la varianza total. La Figura 22 ya deja ver, antes de cualquier clustering formal, dos pares de puntos casi superpuestos (Frontera 01 La Aurora con Vía Aérea, y Frontera 07 Valle Nuevo con Vía Terrestre) y a Vía Marítima claramente aislada del resto.




Figura 23: Clustering jerárquico (Ward) sobre las características catch22 estandarizadas.

Cuadro 17: Asignacion de cluster jerarquico (Ward) para $k=2, 3$ y 4 .

serie	cluster_jerarquico	cluster_kmeans	cluster_k2	cluster_k3	cluster_k4
Total mensual	1	0	1	2	2
Frontera 01 La Aurora	1	0	1	1	1
Frontera 07 Valle Nuevo	1	0	1	2	2
Frontera 09 San Cristóbal	1	0	1	2	3
Vía Aérea	1	0	1	1	1
Vía Terrestre	1	0	1	2	2
Vía Marítima	2	1	2	3	4

El corte estadísticamente óptimo según el coeficiente de silueta fue $k = 2$ (silueta=0.466), que separa a Vía Marítima de las otras seis series, pero no distingue nada más entre ellas. Cortando el mismo dendrograma en $k = 3$ (silueta=0.388, ligeramente menor pero mucho más interpretable) aparece una estructura más rica: {Frontera 01 La Aurora, Vía Aérea} (el par más similar de toda la matriz), {Total mensual, Frontera 07 Valle Nuevo, Frontera 09 San Cristóbal, Vía Terrestre}, y {Vía Marítima} sola.




Figura 24: Heatmap de las 22 características catch22 (estandarizadas) por serie.




Figura 25: Correlación entre las 22 características catch22, calculada sobre las siete series.




Figura 26: Distancia euclidiana entre series en el espacio catch22 estandarizado.

Cuadro 18: Características catch22 con mayor peso combinado en PC1 y PC2.

característica	peso_abs_pc1_pc2	carga_pc1	carga_pc2
DN_HistogramMode_5	0.53	0.19	-0.34
PD_PeriodicityWang_th0_01	0.49	0.10	0.39
SB_MotifThree_quantile_hh	0.47	-0.23	0.24
SC_FluctAnal_2_rsrangefit_50_1_logi_prop_r1	0.43	0.08	0.35
IN_AutoMutualInfoStats_40_gaussian_fmml	0.42	0.03	0.39

8.2.4. Preguntas de interpretación

- **2.7 Series más similares:** Frontera 01 La Aurora y Vía Aérea, con la menor distancia euclidiana de toda la matriz (0.27), consistente con que La Aurora concentra casi todo el tráfico aéreo del país.
- **2.8 Características más discriminantes:** las de mayor peso combinado en PC1+PC2 fueron DN_HistogramMode_5, PD_PeriodicityWang_th0_01, SB_MotifThree_quantile_hh, SC_FluctAnal_2_rsrangefit_50_1_logi_prop_r1 e IN_AutoMutualInfoStats_40_gaussian_fmml (Tabla 18); casi todas relacionadas con la forma de la distribución de valores y con la estructura de autocorrelación/periodicidad.
- **2.9 Grupos naturales:** sí existen – ver el corte $k = 3$ descrito arriba. El grupo {La Aurora, Vía Aérea} comparte un perfil “dominado por un aeropuerto”; el grupo

{Total, Valle Nuevo, San Cristóbal, Vía Terrestre} comparte un perfil más terrestre y heterogéneo en escala; Vía Marítima queda sola por su cobertura incompleta.

- **2.10 Cohesión por categoría:** no es perfecta. Vía Aérea se agrupa con una frontera (La Aurora) y no con las otras dos vías, mientras que Vía Terrestre se agrupa con fronteras terrestres y con el total, no con Vía Aérea. Lo que domina el agrupamiento es la composición real del tráfico (aéreo vs. terrestre) y la escala, no la etiqueta de categoría bajo la cual se construyó la serie.
- **2.11 Serie más atípica:** Vía Marítima, con la mayor distancia promedio respecto al resto (10.66), coherente con su cobertura temporal incompleta y su escala mucho menor.
- **2.12 Consistencia con la Parte 3 del Laboratorio 1:** el agrupamiento catch22 es consistente con la fuerza de estacionalidad, la pendiente de tendencia y el coeficiente de variación de la Tabla 10/11: La Aurora y Vía Aérea comparten valores casi idénticos en las tres métricas ($F_s=0.57$, coeficiente de variación=0.31), y también en los estadísticos ADF de la Parte 1. La única dimensión que no ayuda a diferenciar los grupos es el impacto de la pandemia, porque fue severo de forma casi uniforme en todas las series con datos en ese período.
- **2.13 Descubrimientos no evidentes en el análisis exploratorio tradicional:**
 1. La similitud entre Vía Aérea y Frontera 01 La Aurora, ya intuitiva visualmente, queda confirmada aquí con una métrica de distancia explícita sobre 22 características estadísticas.
 2. catch22 separa a Vía Marítima del resto principalmente por características de autocorrelación y distribución de valores, no solo por su menor volumen, lo que sugiere que su dinámica interna ya era distinta antes de que dejara de reportarse.
 3. El agrupamiento por catch22 no respeta la separación administrativa entre “frontera” y “vía”: la dinámica temporal de una serie está más determinada por su composición de tráfico que por el tipo de categoría bajo la cual fue construida.

8.2.5. 2.14 – LSTM con características catch22

Para aislar el efecto de agregar las características catch22 (sin confundirlo con un cambio de arquitectura), se construyó un modelo con el mismo backbone LSTM del mejor modelo del Ejercicio 1 para **Total mensual** (`look_back=6`, 32 unidades, `dropout=0.1`, `learning_rate=0.001`), añadiendo una segunda entrada: el vector de 22 características catch22 calculado **únicamente con el conjunto de entrenamiento** (para no filtrar información del conjunto de prueba) y normalizado internamente sobre sus propios 22 valores. Ese vector pasa por una capa densa de 8 unidades que se concatena con la salida de la LSTM antes de la capa de salida.

Cuadro 19: LSTM puro contra LSTM + catch22 – Total mensual (conjunto de prueba).

Serie	Modelo	MAE	RMSE	MAPE	R2
Total mensual	LSTM (Ejercicio 1)	40554.45	50794.23	18.05	0.54
Total mensual	LSTM + catch22 (2.14)	60182.80	73537.01	31.85	0.04




Figura 27: LSTM puro (Ejercicio 1) contra LSTM + catch22 (Ejercicio 2.14) – Total mensual, conjunto de prueba.

El RMSE de prueba **empeoró** 44.8 % al agregar catch22 (de 50 794 a 73 537), con una caída marcada de R^2 (de 0.543 a 0.043). La Figura 27 muestra por qué: el modelo con catch22 subestima fuertemente el tramo inicial de recuperación pospandemia (2021-2022), llegando incluso a predecir valores negativos al principio del horizonte de prueba.

La explicación es metodológica: para una única serie, el vector catch22 es una **constante** (no cambia entre observaciones de esa misma serie), por lo que la rama densa que lo procesa solo puede aportar un término de sesgo adicional a la red – no aporta información temporal nueva dentro de la serie. La diferencia de desempeño frente al LSTM puro se explica entonces por la capacidad extra del modelo (una capa densa y una concatenación adicionales que el optimizador debe ajustar con los mismos datos de entrenamiento), no por un uso genuino de catch22 como señal predictiva; en este caso esa capacidad extra jugó en contra del modelo. El valor real de catch22 en un modelo de deep learning no está en enriquecer una LSTM entrenada sobre una sola serie, sino en escenarios donde el mismo modelo pronostica **varias series a la vez**: allí el vector catch22 sí varía de una serie a otra y podría actuar como un identificador de contexto (estacionalidad alta, dominada por un aeropuerto, etc.) que permita compartir capacidad entre series similares – como Frontera 01 La Aurora y Vía Aérea, identificadas como las más parecidas en este mismo ejercicio – sin entrenar un modelo independiente para cada una. Esa aplicación más ambiciosa queda fuera del alcance de este ejercicio, que compara un LSTM contra su versión aumentada sobre una sola serie.